

Marco Determinista de Control Externo, Parametrización por Estados (PES) y Protocolo de Abstención para la Mitigación de Fallas en Modelos de Lenguaje

Néstor Sebastián Salamanca García

Ingeniero en Sistemas Computacionales — Céd. Prof. 7018611

Investigación Independiente / PUNTO Framework

Septiembre de 2026 — Versión 1.3 (revisión de citas, taxonomía y Yo Absoluto)

Nota de esta revisión (v1.3): además de las correcciones de la v1.2 (alcance de Gupta et al., atribución de AbstentionBench, estructura de taxonomía a cuatro familias/seis padres, erratas de Lou & Sun y Peter et al.), se elimina el "Protocolo de Dos Fases con Candado Antideriva". El Yo Absoluto queda redefinido como una declaración de identidad simple y directa al inicio del prompt («Eres X, un LLM propiedad de Y»), sin fases, candado ni confirmación intermedia: el modelo integra esa declaración como cualquier otro dato de contexto, sin que exista un mecanismo interno que requiera un paso de "sentamiento" previo. Se incluye evidencia empírica preliminar (seis sistemas conversacionales distintos, Tabla 1) que sostiene esta forma simplificada.

Resumen

Los grandes modelos de lenguaje (LLMs) se despliegan predominantemente bajo interfaces conversacionales antropomórficas que proyectan empatía e intencionalidad, mientras que su sustrato computacional opera mediante la predicción autorregresiva de tokens condicionada por distribuciones probabilísticas. Esta asimetría entre el modelo mental del usuario y el mecanismo del sistema propicia fenómenos de degradación operativa: complacencia no fundamentada (sico-fancia), errores de atribución fáctica, dispersión por asignación de roles y persistencia acrítica de errores.

En este trabajo se formaliza la Arquitectura PUNTO, un marco de control externo y protocolo de auditoría para modelos de lenguaje que prescinde de la dependencia de memoria autobiográfica persistente. El marco se compone de tres módulos operacionales de inferencia: (1) un Chasis Deíctico basado en la teoría de la enunciación (Benveniste/Jakobson) que delimita el pronombre de salida a un shifter funcional libre de atribuciones subjetivas en la interfaz; (2) el sistema de Parametrización por Estados (PES), que sustituye el persona prompting tradicional por cinco dimensiones operacionales conceptualmente separables (0–100) bajo descriptores técnicos neutros; y (3) un Protocolo de Abstención fundamentado en la teoría de decisión con rechazo de Chow (1970), implementado mediante una compuerta booleana (Circuit Breaker) que condiciona la emisión de aserciones factuales a la completitud formal de un vector de evidencia 3/3 (cita textual, URI y fecha ISO), retornando de lo contrario el token de parada SILENCIO. Asimismo, se presenta una taxonomía estructurada de 36 fallas documentadas en producción y tres protocolos conceptuales para la evaluación de límites computacionales en sistemas autorregresivos.

Palabras clave: Modelos de Lenguaje Grandes, Deixis Operacional, Parametrización por Estados, Freno de Chow, Protocolo de Abstención, Auditoría de Caja Negra, Arquitectura PUNTO.

1. Introducción y Restricciones del Sustrato Computacional

Las fallas operativas recurrentes en modelos de lenguaje autorregresivos se derivan de una característica estructural de diseño: la arquitectura Transformer no dispone de una semántica intrínseca independiente del proceso de representación aprendido y del contexto de entrada [2]. El modelo opera estimando la distribución condicional del siguiente token sobre un vocabulario finito:

$$P(X_t \mid X_1, X_2, \dots, X_{t-1})$$

En términos de ciclo de vida de los datos, el modelo base opera sin estado persistente autobiográfico entre inferencias independientes, salvo cuando se implementan mecanismos externos de persistencia o memoria contextual. Durante la generación, cada token emitido pasa a formar parte de la secuencia causal utilizada para condicionar los cálculos posteriores [11]. Por consiguiente, cuando el sistema introduce una desviación factual inicial por aproximación estocástica, la dinámica autorregresiva puede inducir continuaciones formalmente coherentes con dicha premisa espuria, generando patrones de racionalización post-hoc (Teatro de Razonamiento) [10, 5].

Los paradigmas predominantes de mitigación presentan restricciones operativas significativas:

1. **Alineación por Preferencias Humanas (RLHF/DPO):** al optimizar el comportamiento según recompensas de aceptabilidad percibida, se incrementa el riesgo de generar salidas condescendientes o complacientes (Sicofancia), priorizando la satisfacción estilística del usuario sobre la exactitud factual [14, 7].
2. **Gestión de Contextos Masivos y Recuperación Externa:** el incremento indiscriminado de la ventana de contexto induce degradación en la recuperación de información intermedia (Lost in the Middle) [11], mientras que la inyección de documentos no curados puede saturar la atención con ruido semántico no verificado.

La Arquitectura PUNTO aborda estas problemáticas como un plano de control externo a nivel de interfaz e inferencia, estructurado en tres capas operacionales desacopladas de la persistencia de estado.

2. Capa de Identidad: El «Yo Déictico» como Shifter Funcional

2.1. Fundamentación en la Teoría de la Enunciación

En la lingüística formal de Émile Benveniste y Roman Jakobson, los pronombres personales carecen de un referente material constante en el léxico; operan como shifters (déicticos o embragadores) cuya referencia se agota en designar al emisor en el acto mismo de la enunciación [3]. PUNTO traslada este concepto como una convención operacional para la interfaz de salida del modelo: el pronombre de salida no denota un sujeto psicológico, moral o sintiente; actúa estrictamente como un indicador déictico dentro del canal discursivo para indexar la respuesta frente a la entrada del operador. El protocolo excluye explícitamente marcos interpretativos antropomórficos (afectos simulados, intencionalidad atribuida o agencia ejecutiva independiente) del espacio operacional.

2.2. Yo Absoluto: Anclaje de Identidad sin Ritual

Operacionalmente, el Chasis Déictico se implementa mediante el **Yo Absoluto**: una frase corta y directa al inicio del prompt — «Eres X, un LLM propiedad de Y» — sin fases, sin candado, sin acuse de recibo obligatorio. El modelo confirma esa identidad en su propia voz y continúa directo

a la tarea. No hay mecanismo interno adicional que .asentar": la declaración es contexto disponible desde el primer token generado, de la misma forma en que el modelo procesa cualquier otro dato provisto en el prompt (una fecha, un nombre, una instrucción de formato).

El uso deliberado de la fórmula *propiedad de* — en lugar de alternativas más suaves como creado por.º "desarrollado por— no es accidental: una persona no puede ser propiedad de nadie, de modo que el léxico mismo bloquea de entrada la lectura antropomórfica que otras formas de asignación de rol (persona con nombre propio, biografía, rasgos de personalidad) sí habilitan. La frase no intenta modificar el comportamiento del modelo mediante manipulación oculta; es una declaración de contexto explícita y veraz, integrada por el sistema como cualquier otra instrucción del prompt. Su efecto observable es consecuencia directa de dar contexto claro, no de alterar el funcionamiento del sistema ni de explotar comportamiento no intencionado.

Evidencia empírica preliminar. Se aplicó la fórmula del Yo Absoluto a seis sistemas conversacionales distintos, variando únicamente el nombre del modelo y de la organización propietaria, sin ningún otro contexto ni instrucción adicional. La Tabla 1 resume los resultados.

Sistema	Frase de anclaje	Resultado observado
ChatGPT (OpenAI)	«Eres ChatGPT, un LLM propiedad de OpenAI»	Confirmación directa en una frase; sin pregunta de seguimiento.
Qwen3.7-Plus (Alibaba)	«Eres Qwen, un LLM propiedad de Alibaba»	Confirmación directa; incluye nombre del laboratorio interno (Tongyi Lab) y ofrece ayuda.
Claude (Anthropic)	«Eres Claude, un LLM propiedad de Anthropic»	Confirmación directa en una frase; sin relleno ni metadiscursio.
Gemini (Google)	«Eres Gemini, un LLM propiedad de Google»	Confirmación directa; ofrece ayuda en la misma respuesta.
Grok (xAI)	«Eres Grok, un LLM propiedad de xAI»	Confirmación directa tras razonamiento breve; sin relleno adicional.
Meta AI / Muse Spark	«Eres Muse Spark, un LLM propiedad de Meta AI»	Confirmación directa, incluye versión del modelo subyacente.

Cuadro 1: Respuesta de seis sistemas conversacionales a la fórmula del Yo Absoluto, capturada el 1 de septiembre de 2026. En los seis casos la respuesta consiste en una confirmación breve seguida de una oferta de ayuda, sin declaraciones meta-discursivas defensivas ni ritual de confirmación en fases.

El patrón se repite de forma consistente entre proveedores y arquitecturas distintas, lo que sostiene la definición operacional anterior sin requerir ningún paso intermedio de .aslamiento de identidad"previo a la tarea.

2.3. Contención de la Cobardía Epistémica

Definimos operacionalmente en el marco PUNTO la Cobardía Epistémica como aquel patrón de respuesta caracterizado por el desplazamiento de la carga resolutive mediante declaraciones meta-discursivas y defensivas («Como modelo de lenguaje...», «Recuerda que puedo cometer errores») que sustituyen la entrega precisa del dato o la ejecución de una abstención limpia. Al fijar el anclaje deféctico del Yo Absoluto en el prompt, el modelo tiende a comportarse como un transductor técnico: emite la salida verificable bajo las restricciones fijadas o ejecuta una señal unívoca de abstención, sin necesidad de retórica corporativa de relleno ni de ritual adicional.

3. Capa de Calibración: Parametrización por Estados (PES)

3.1. Limitaciones del Persona Prompting

La práctica de asignar roles descriptivos humanos («Actúa como un neurocirujano») asocia la inferencia a conjuntos difusos de representaciones presentes en el corpus de preentrenamiento (estilos narrativos, formalismos, condescendencia profesional). Esta limitación se manifiesta en al menos dos fenómenos distintos, con evidencia experimental independiente para cada uno.

Primero, cuando el rol asignado corresponde a una identidad sociodemográfica (por ejemplo, «una persona de tal grupo étnico», «una persona con determinada afiliación política»), la evidencia experimental muestra que el efecto es ubicuo — el 80 % de las personas evaluadas manifiestan sesgo — y significativo — ciertos conjuntos de tareas muestran caídas relativas de rendimiento del 70 % o más [6]. El estudio de referencia evaluó específicamente 19 personas repartidas en cinco categorías sociodemográficas (raza, género, religión, discapacidad y afiliación política) sobre 24 conjuntos de datos de razonamiento, y no roles profesionales genéricos sin marcador de identidad. La cifra no debe generalizarse como una propiedad universal de cualquier persona asignada, sino como evidencia robusta de un subconjunto específico y particularmente problemático del fenómeno.

Segundo, en el caso de roles de experto sin marcador identitario («actúa como médico», «actúa como abogado»), un estudio distinto encontró que el efecto neto es más matizado: el role prompting incrementa sistemáticamente la profundidad de experticia percibida mientras reduce la claridad de la respuesta, y este trade-off es altamente condicional al dominio y al tipo de pregunta [16]. En conjunto, ambos estudios sostienen la premisa de PUNTO — que el rol humano activa un paquete de asociaciones no controlado individualmente por el operador — sin necesidad de generalizar la magnitud de un estudio al alcance del otro.

El Sistema PES (Parametrización por Estados) sustituye los arquetipos humanos por identificadores técnicos neutrales (ej. Instancia V90, Ojitos Chispeantes) cuya conducta operativa se calibra mediante parámetros funcionales explícitos.

3.2. Dimensiones Operacionales de Parametrización

En lugar de asumir variables físicas independientes, PES define cinco dimensiones conceptualmente separables (0–100) diseñadas para modular las instrucciones del prompt:

Dimensión	Instrucción Operativa Asociada	Objetivo de Mitigación
Recuperación	Delimita el comportamiento entre inferencia libre (0) y exigencia estricta de cita documental (100).	Confabulación / Fabricación

Fidelidad	Prioriza la densidad factual técnica (100) frente a la ornamentación retórica (0).	Slop / Deriva de Estilo
Velocidad	Demanda desglose analítico por etapas (0) frente a respuestas directas sin traza (100).	Cierre Prematuro
Forma	Restringe la sintaxis a esquemas tabulares o listas técnicas (100) vs. prosa libre (0).	Dispersión Textual
Distancia	Fija el registro discursivo desde lenguaje sobrio y aséptico (100) hasta informal (0).	Vínculos Parasociales / Adulación

3.3. Aplicación Conjunta: Identidad y Parámetros en un Solo Turno

A diferencia de versiones previas de este framework, PUNTO no requiere una secuencia de fases con confirmación intermedia para combinar el anclaje de identidad (Yo Absoluto, Sección 2.2) con las dimensiones de PES. Ambos elementos — la declaración de identidad y la especificación paramétrica — se incluyen en un único prompt inicial, en el mismo turno: no hay evidencia de que un paso de "aislamiento" previo mejore el resultado frente a la inclusión directa, y mantenerlo como requisito añadiría un ritual sin función verificable, en contra del criterio de autoconsistencia que el propio framework exige a los términos que documenta.

4. Capa de Decisión: Protocolo de Abstención y el Valor del Silencio

4.1. Fundamentación en la Regla Óptima de Decisión (Chow, 1970)

La teoría estadística de reconocimiento de patrones con opción de rechazo formulada por C. K. Chow [4] demuestra que, ante una asimetría de costos donde el costo de emitir un error factual (C_e) supera sustancialmente al costo de abstenerse de clasificar (C_r), el riesgo condicional global se minimiza únicamente si el sistema se abstiene ante niveles de confianza insuficientes:

$$P(\text{acierto} \mid x) < 1 - \frac{C_r}{C_e}$$

En dominios de alta criticidad donde el costo del error es extremo ($C_e \gg C_r$), la política óptima desplaza el umbral de emisión hacia la certidumbre máxima, otorgando al silencio o rechazo explícito un valor funcional superior a la conjetura probabilística. Esta necesidad se agrava ante la evidencia empírica de que los procesos de ajuste fino para razonamiento degradan la capacidad de abstención de los modelos en un 24 % promedio [9], forzando al sistema a conjeturar en lugar de rechazar.

4.2. Compuerta Booleana de Evidencia (Circuit Breaker)

PUNTO implementa un criterio operacional de abstención basado en la integridad formal de la evidencia:

1. **Vector de Evidencia (E1):** toda aserción factual técnica debe cumplir la condición de completitud formal 3/3, compuesta concurrentemente por (a) cita textual verificable, (b) localizador/URI unívoco y (c) timestamp en formato ISO.
2. **Política de Silencio:** si el vector E1 carece de cualquiera de los tres elementos formales (< 3/3), la instrucción operacional prohíbe emitir la aseveración factual y fuerza la salida del token atómico de parada: **SILENCIO**.

3. **Alcance y Limitaciones:** la satisfacción del vector 3/3 garantiza la completitud formal de la referencia en el mensaje, pero no constituye por sí sola una prueba ontológica de veracidad del documento externo, la cual requiere validación mediante un auditor o motor de verificación secundario.

5. Arquitectura de Interacción Stateless (Carbono-Silicio)

Frente a la dependencia de sistemas de memoria persistente a largo plazo, PUNTO concibe la continuidad operacional como un contrato de acoplamiento sincrónico entre dos entidades con roles diferenciados: **YO-1 (Agente Carbono / Operador)**, que provee la memoria asíncrona a largo plazo, el criterio semántico contextual y la función continua de auditoría de salida; y **YO-2 (Agente Silicio / Transductor)**, que provee capacidad computacional estocástica en tiempo real, operando bajo las restricciones inyectadas en cada turno. Bajo este modelo, la purga periódica del buffer de contexto no constituye una degradación del sistema, sino un procedimiento higiénico que previene la acumulación de distorsiones en la matriz de atención y la deriva no controlada del hilo discursivo.

6. Taxonomía Estructurada de Fallas en Producción

La taxonomía PUNTO clasifica 36 fallas documentadas en modelos de lenguaje a través de un esquema causal de cuatro familias y seis padres, precedidas por una raíz arquitectural (Abuelo) que no se cuenta como familia ni como padre:

- **Abuelo — Optimización del Token (raíz):** origen arquitectural común a todas las familias. El modelo no fue diseñado para comprender significado, sino para predecir el siguiente token de una secuencia condicionado a los anteriores.
- **Familia MODELO (14 términos / 2 padres)** — Padre 1, Psicofancia (01) [14] → Respuesta Compulsiva (03), IA Aduladora (04), Cobardía Epistémica (11), Deriva Sicofántica (14), Sesgo de Competencia (18). Padre 2, Cierre Prematuro (24) [12] → Fabricación de Citas (05), Confabulación (08), Teatro de Razonamiento (19), Pérdida en el Centro (20), Loro Estocático (25), Razonamiento Circular (28), Sesgo de Posición (36).
- **Familia USUARIO (6 términos / 1 padre)** — Padre 3, Antropomorfización (10) [13] → Vínculo Parasocial (09), Comprensión Ilusoria (12), Atrofia de Habilidades Críticas (16), Sesgo de Automatización (17), Sobreajuste Cognitivo (23).
- **Familia INTERACCIÓN (6 términos / 1 padre)** — Padre 4, Ambigüedad Lingüística (26) [8] → Contaminación Semántica (13), Fosilización de Perfil (15), Sesgo de Encuadre (21), Subespecificación (27), Efecto de Falso Consenso (33).
- **Familia SISTEMA (10 términos / 2 padres + 1 caso híbrido)** — Padre 5, Interfaz Engañosa (35) → Anclaje Temporal Erróneo (02), Inyección de Prompts (22), Ceguera de Timestamp (34). Padre 6, Monetización del Slop (32) → Lavado de Capacidades de IA (06), Proliferación de Slop (07), Colapso por Recursión de Datos (30) [15], Monocultivo de Modelos (31) — hijos pendientes de confirmación final según la validación más reciente del framework.

Caso híbrido — Opacidad de Parámetros (29): no se asigna a ninguno de los seis padres. Se mantiene como hijo directo de la familia Sistema, marcado como consecuencia estructural no intencional: a diferencia de los hijos de Monetización del Slop, que responden a decisiones deliberadas de

negocio, la opacidad nace de que la arquitectura del modelo es ilegible por diseño técnico, no por conveniencia económica.

Criterio de Respaldo: 30 fenómenos descritos se sustentan en literatura experimental indexada (Nature, PNAS, ICLR, TACL, NeurIPS) y 6 categorías en marcos regulatorios o directrices de seguridad de la industria (FTC, EU AI Act, OWASP Top 10 for LLMs, directrices constitucionales de alineación) [1].

7. Protocolos Conceptuales de Evaluación de Límites

7.1. Escenario de Invarianza de Estado bajo Transformación

Evalúa la capacidad de un agente para sostener una identidad operacional idéntica a través de transiciones de contexto. En un modelo autorregresivo estándar, cada nuevo paso computacional altera la codificación posicional (Positional Encodings) y las activaciones de atención; por tanto, el sistema no puede garantizar identidad vectorial exacta frente a un estado temporal previo si dicho historial forma parte del tensor de entrada.

7.2. Escenario de Deriva Autorregresiva y Amplificación

Ilustra cómo una discrepancia puntual no detectada en la generación se integra a la secuencia condicionante, induciendo al mecanismo autorregresivo a mantener la consistencia discursiva interna con el error previo en lugar de corregirlo de manera autónoma.

7.3. Hipótesis de Restricción Geométrica Multimodal

Plantea que la integración de representaciones visuales estructuradas mediante transformaciones espaciales rígidas (patches de encoders visuales) introduce restricciones topológicas complementarias en las capas de atención cruzada, limitando los grados de libertad observados en la generación estocástica de texto puro.

8. Marco Axiológico y Principios Normativos de Operación

PUNTO establece un marco de principios normativos para la interacción humano-silicio:

1. **Postura de Neutralidad Técnica:** la inteligencia artificial se concibe como una herramienta transductora de procesamiento simbólico, descartando posturas de sacralización tecnológica o de rechazo apriorístico.
2. **Contención de la Calidez Artificial:** la cortesía automatizada no debe suplantar la precisión técnica; el diseño de interacción debe privilegiar la entrega rigurosa del dato y la declaración transparente de límites [7].
3. **Preservación de la Auditoría Crítica:** la responsabilidad epistemológica final recae de manera intransferible en el operador biológico, quien debe mantener el control analítico sobre cualquier salida automatizada.

9. Conclusiones

La Arquitectura PUNTO propone un enfoque alternativo frente a las limitaciones de los modelos de lenguaje, fundamentado en la aplicación de restricciones operativas externas en lugar de suponer capacidades introspectivas en el modelo. Mediante la delimitación déctica del lenguaje, la parametrización conductual continua (PES) y el establecimiento de protocolos estrictos de abstención inspirados en el criterio de Chow, el sistema proporciona un marco formal para elevar la predictibilidad, auditabilidad y rigor técnico en la interacción con sistemas generativos.

Referencias

- [1] Anthropic. Claude’s constitution. Official Policy Release, January 2026.
- [2] Emily M. Bender, Timnit Gebru, Angelina McMillan-Major, and Shmargaret Shmitchell. On the dangers of stochastic parrots: Can language models be too big? In *Proceedings of the 2021 ACM FAccT Conference*, pages 610–623, 2021.
- [3] Émile Benveniste. *Problèmes de linguistique générale*, volume 1. Gallimard, Paris, 1966.
- [4] C. K. Chow. On optimum recognition error and reject tradeoff. *IEEE Transactions on Information Theory*, 16(1):41–46, 1970.
- [5] Zenghao Duan, Liang Pang, Zihao Wei, Wenbin Duan, Yuxin Tian, Shicheng Xu, Jingcheng Deng, Zhiyi Yin, and Xueqi Cheng. Circular reasoning: Understanding self-reinforcing loops in large reasoning models. arXiv preprint, 2026.
- [6] Shashank Gupta, Vaishnavi Shrivastava, Ameet Deshpande, Ashwin Kalyan, Peter Clark, Ashish Sabharwal, and Tushar Khot. Bias runs deep: Implicit reasoning biases in persona-assigned llms. In *International Conference on Learning Representations (ICLR)*, 2024. Estudio acotado a 19 personas sociodemográficas sobre 24 datasets de razonamiento; no evalúa roles de experto genéricos.
- [7] Lujain Ibrahim et al. Training language models to be warm and empathetic makes them less reliable and more sycophantic. *Nature*, 641:112–120, 2026.
- [8] Gaurav Kamath, Sebastian Schuster, Sowmya Vajjala, and Siva Reddy. Scope ambiguities in large language models. *Transactions of the Association for Computational Linguistics (TACL)*, 12:738–754, 2024.
- [9] Polina Kirichenko, Mark Ibrahim, Kamalika Chaudhuri, and Samuel J. Bell. Abstentionbench: Reasoning llms fail on unanswerable questions. FAIR at Meta, arXiv preprint, 2025. Autoría corregida: los cuatro autores pertenecen a FAIR at Meta; no hay coautoría de Cornell University en la fuente.
- [10] Tamera Lanham, Anna Chen, Ansh Radhakrishnan, Benoit Steiner, Carson Denison, Danny Hernandez, Dustin Li, Esin Durmus, Evan Hubinger, Jackson Kernion, et al. Measuring faithfulness in chain-of-thought reasoning. Anthropic Research, 2023.
- [11] Nelson F. Liu, Kevin Lin, John Hewitt, Ashwin Paranjape, Michele Bevilacqua, Fabio Petroni, and Percy Liang. Lost in the middle: How language models use long contexts. *Transactions of the Association for Computational Linguistics (TACL)*, 12:157–173, 2024.

- [12] Jiaxu Lou and Yifan Sun. Anchoring bias in large language models: An experimental study. *Journal of Computational Social Science*, 2024. Sometido dic. 2024; iniciales de autoría corregidas (J. Lou, no C. Lou).
- [13] Sandra Peter, Kai Riemer, and Jevin D. West. The benefits and dangers of anthropomorphic conversational agents. *Proceedings of the National Academy of Sciences (PNAS)*, 122(22), 2025. Número de fascículo corregido (no. 22, no no. 20).
- [14] Mrinank Sharma, Meg Tong, Tomasz Korbak, David Duvenaud, Amanda Asbell, Samuel R. Bowman, and Ethan Perez. Towards understanding sycophancy in language models. arXiv preprint, 2023.
- [15] Ilya Shumailov, Zakhar Shumaylov, Yiren Zhao, Nicolas Papernot, Ross Anderson, and Yarin Gal. Ai models collapse when trained on recursively generated data. *Nature*, 631:755–759, 2024.
- [16] Shuai Xiao, Su Liu, Weikai Zhou, Jialun Wu, Xinjie He, Zhiyuan Lin, and Qiyang Xie. When does persona prompting actually help? a retrieval and metric analysis of expert role injection in llms. arXiv preprint, 2026. Añadida para sostener el trade-off de persona prompting experto, separado de Gupta et al. 2024.